Obliczenia Naukowe - Sprawozdanie nr $1\,$

Jędrzej Sajnóg, indeks: 279701

23października 2025

Spis treści

1	Zad	lanie 1: Rozpoznanie arytmetyki								
	1.1	Krótki opis problemu								
	1.2	Rozwiązanie								
	1.3	Wyniki i interpretacja								
		1.3.1 Wyjście programów w Julii								
		1.3.2 Wyjście programu w C								
	1.4	Wnioski								
2	Zadanie 2: Wzór Kahana na epsilon maszynowy									
	2.1	Krótki opis problemu								
	2.2	Rozwiązanie								
	2.3	Wyniki i interpretacja								
	2.4	Wnioski								
3	Zadanie 3: Rozmieszczenie liczb zmiennoprzecinkowych									
	3.1	Krótki opis problemu								
	3.2	Rozwiązanie								
	3.3	Wyniki i interpretacja								
	3.4	Wnioski								
4	Zadanie 4: Utrata precyzji									
	4.1	Krótki opis problemu								
	4.2	Rozwiązanie								
	4.3	Wyniki i interpretacja								
	4.4	Wnioski								
5	Zad	Zadanie 5: Obliczanie iloczynu skalarnego								
	5.1	Krótki opis problemu								
	5.2	Rozwiązanie								
	5.3	Wyniki i interpretacja								
	5.4	Wnioski								
6	Zad	lanie 6: Numeryczna stabilność wzorów								
	6.1	Krótki opis problemu								
	6.2	Rozwiązanie								
	6.3	Wyniki i interpretacja								
	6.4	Wnioski								
7	Zad	lanie 7: Różniczkowanie numeryczne								
	7.1	Krótki opis problemu								
	7.2	Rozwiązanie								
	7.3	Wyniki i interpretacja								
	7.4	Wnioski								

1 Zadanie 1: Rozpoznanie arytmetyki

1.1 Krótki opis problemu

Zadanie polega na iteracyjnym wyznaczeniu stałych charakteryzujących arytmetykę zmiennoprzecinkową dla typów Float16, Float32 i Float64 w języku Julia. Należy znaleźć:

- Epsilon maszynowy (macheps): najmniejsza liczba > 0 taka, że 1.0 + macheps > 1.0.
- Liczbę eta: najmniejsza reprezentowalna dodatnia liczba maszynowa.
- Maksymalną wartość (MAX): największa skończona liczba maszynowa.

Uzyskane wyniki należy porównać z wartościami zwracanymi przez wbudowane funkcje Julii oraz z wartościami zdefiniowanymi w pliku nagłówkowym języka C (float.h).

1.2 Rozwiązanie

Do wyznaczenia wartości zostały zaimplementowane trzy funkcje w języku Julia.

- Epsilon maszynowy: Algorytm rozpoczyna od wartości add = 1.0 i w pętli dzieli ją przez 2, dopóki warunek 1.0 + add > 1.0 jest spełniony. Ostatnia wartość spełniająca ten warunek jest szukanym epsilonem.
- Eta: Algorytm działa podobnie, ale sprawdza warunek 0.0 + add > 0.0.
- MAX: Algorytm najpierw znajduje największą potęgę dwójki mniejszą od nieskończoności, mnożąc iteracyjnie 1.0 przez 2. Następnie, aby uzyskać największą możliwą wartość, wynik ten jest mnożony przez (2 – macheps), co odpowiada ustawieniu wszystkich bitów mantysy na 1.

1.3 Wyniki i interpretacja

1.3.1 Wyjście programów w Julii

```
# julia zad1_epsilon.jl
Type: Float16, calculated epsilon: 0.000977, true_epsilon: 0.000977
Type: Float32, calculated epsilon: 1.1920929e-7, true_epsilon: 1.1920929e-7
Type: Float64, calculated epsilon: 2.220446049250313e-16, true_epsilon: 2.220446049250313e-16

# julia zad1_eta.jl
Type: Float16, calculated eta: 6.0e-8, true_eta: 6.0e-8
Type: Float32, calculated eta: 1.0e-45, true_eta: 1.0e-45
Type: Float64, calculated eta: 5.0e-324, true_eta: 5.0e-324

# julia zad1_MAX.jl
Type: Float16, calculated max: 6.55e4, true_max: 6.55e4
Type: Float32, calculated max: 3.4028235e38, true_max: 3.4028235e38
Type: Float64, calculated max: 1.7976931348623157e308, true_max: 1.7976931348623157e308
```

1.3.2 Wyjście programu w C

```
# ./a.out
```

```
Float32 max: 3.40282346638528859812e+38
Float64 max: 1.79769313486231570815e+308
Float32 eps: 1.19209289550781250000e-07
Float64 eps: 2.22044604925031308085e-16
```

Wartości obliczone iteracyjnie są równe wartościom zwracanym przez funkcje wbudowane w Julii (eps(), nextfloat(zero()), floatmax()). Są one również zgodne ze stałymi zdefiniowanymi w standardzie języka C (FLT_EPSILON, DBL_EPSILON, FLT_MAX, DBL_MAX).

Związki między liczbami:

- precyzja arytmetyki ϵ to górne ograniczenie błędu względnego dla danej arytmetyki, macheps to najmniejsza wartość taka, że 1+macheps > 1. $\epsilon = \frac{1}{2}$ macheps
- eta to najmniejsza dodatnia liczba subnormalna (MINsub), czyli najmniejsza wartość > 0, jaką można zapisać.
- Funkcja floatmin(T) zwraca najmniejszą dodatnią liczbę normalną (MINnor).

1.4 Wnioski

Zaproponowane algorytmy iteracyjne poprawnie wyznaczają kluczowe stałe arytmetyki zmiennoprzecinkowej. Zgodność wyników z wartościami standardowymi potwierdza ich poprawność oraz ilustruje fundamentalne właściwości standardu IEEE 754.

2 Zadanie 2: Wzór Kahana na epsilon maszynowy

2.1 Krótki opis problemu

Zadanie polega na eksperymentalnym sprawdzeniu w języku Julia stwierdzenia Williama Kahana, że epsilon maszynowy można obliczyć za pomocą wyrażenia 3(4/3-1)-1.

2.2 Rozwiązanie

Obliczenie wyrażenia 3(4/3-1)-1.

2.3 Wyniki i interpretacja

```
# julia zad2.jl
Type: Float16, true epsilon: 0.000977, approx: -0.000977
Type: Float32, true epsilon: 1.1920929e-7, approx: 1.1920929e-7
Type: Float64, true epsilon: 2.220446049250313e-16, approx: -2.220446049250313e-16
```

Dla typu Float
32 wzór dał dokładną wartość epsilonu. Dla Float
16 i Float
64 wynik jest równy wartości przeciwnej do epsilonu. W zależności od długości mantysy wartość obliczonego może wynosić $+/-\epsilon$

2.4 Wnioski

Wzór Kahana jest poprawną metodą obliczania epsilonu maszynowego.

3 Zadanie 3: Rozmieszczenie liczb zmiennoprzecinkowych

3.1 Krótki opis problemu

Zadanie polega na zbadaniu, jak rozmieszczone są liczby zmiennoprzecinkowe w standardzie IEEE 754 (dla typu Float64) w różnych przedziałach: [1,2], [1/2,1] oraz [2,4].

3.2 Rozwiązanie

W przedziale [1,2) wszystkie liczby mają ten sam wykładnik, a różnią się jedynie 52-bitową mantysą. Oznacza to, że są one rozmieszczone równomiernie, a odległość między dwiema kolejnymi liczbami (krok δ) jest stała i wynosi 2^{-52} . W innych przedziałach, będących potęgami dwójki, krok ten ulega skalowaniu. W przedziale $[2^k, 2^{k+1})$ krok wynosi $2^k \cdot 2^{-52}$. Do analizy został napisany program, który wyświetla reprezentacje binarne kolejnych liczb w danym przedziale, aby zobrazować zmiany w mantysie.

3.3 Wyniki i interpretacja

Analiza reprezentacji binarnych i wartości liczbowych potwierdza teorię. Widać, że wykładnik (01111111110) pozostaje stały, a zmienia się jedynie mantysa, która jest inkrementowana o 1 na najmłodszej pozycji. To prowadzi do równomiernego rozmieszczenia liczb w tym przedziale.

- W przedziale [1, 2] krok $\delta = 2^{-52}$.
- W przedziałe [1/2, 1] krok $\delta = 2^{-53}$. Liczby są rozmieszczone dwa razy gęściej.
- W przedziale [2,4] krok $\delta = 2^{-51}$. Liczby są rozmieszczone dwa razy rzadziej.

Każde przekroczenie potegi dwójki powoduje zmiane wykładnika, zwiększając wartość kroku δ .

3.4 Wnioski

Liczby zmiennoprzecinkowe nie są rozmieszczone równomiernie na osi liczbowej. Ich gęstość jest największa w okolicy zera i maleje wraz ze wzrostem wartości bezwzględnej.

4 Zadanie 4: Utrata precyzji

4.1 Krótki opis problemu

Zadanie polega na znalezieniu najmniejszej liczby zmiennoprzecinkowej x w przedziale (1,2) dla typu Float64, dla której operacja $x \cdot (1/x)$ nie jest równa 1.

4.2 Rozwiązanie

Problem wynika z błędów zaokrągleń. Obliczenie odwrotności 1/x może nie być dokładne w arytmetyce binarnej. Ten błąd, nawet niewielki, po pomnożeniu z powrotem przez x może spowodować, że końcowy wynik będzie różnił się od 1. Algorytm iteruje od 1 w górę z krokiem równym epsilonowi maszynowemu i sprawdza warunek $x \cdot (1/x) \neq 1$.

4.3 Wyniki i interpretacja

4.4 Wnioski

Operacje w arytmetyce zmiennoprzecinkowej są obarczone błędami związanymi z przybliżaniem liczb. Podstawowe prawa arytmetyki (np. istnienie elementu odwrotnego) nie zawsze są spełnione w arytmetyce zmiennoprzecinkowej.

5 Zadanie 5: Obliczanie iloczynu skalarnego

5.1 Krótki opis problemu

Zadanie polega na obliczeniu iloczynu skalarnego dwóch wektorów na cztery różne sposoby, używając pojedynczej (Float32) i podwójnej (Float64) precyzji. Celem jest zbadanie wpływu kolejności sumowania na wynik.

5.2 Rozwiązanie

Zaimplementowano cztery algorytmy sumowania iloczynów x_iy_i :

- 1. W przód: Standardowa pętla od i = 1 do n.
- 2. W tył: Petla od i = n do 1.
- 3. **Od największego do najmniejszego:** Iloczyny są sortowane malejąco wg wartości bezwzględnej (osobno dodatnie, osobno ujemne), a następnie sumowane.
- 4. Od najmniejszego do największego: Analogicznie, ale sortowane rosnaco.

5.3 Wyniki i interpretacja

```
# julia zad5.jl
======Current type: Float32======
x: Float32[2.7182817, -3.1415927, 1.4142135, 0.5772157, 0.30103],
y: Float32[1486.2498, 878367.0, -22.37492, 4.7737145f6, 0.000185049]
True sum: -1.0065710699999998e-11
Forward: -0.4999443, : 4.966805766128285e10
Backward: -0.4543457, : 4.5137965580009605e10
Large to small: -0.5, : 4.967359135306108e10
Small to large: -0.5, : 4.967359135306108e10
======Current type: Float64======
x: [2.718281828, -3.141592654, 1.414213562, 0.5772156649, 0.3010299957],
y: [1486.2497, 878366.9879, -22.37492, 4.773714647e6, 0.000185049]
True sum: -1.0065710699999998e-11
Forward: 1.0251881368296672e-10, : 11.184955313981629
Backward: -1.5643308870494366e-10, : 14.541186645165917
Large to small: 0.0, : 1.0
Small to large: 0.0, : 1.0
```

Dla typu Float32, wszystkie metody dały całkowicie błędne wyniki. Ograniczona precyzja nie jest w stanie poradzić sobie z dużymi różnicami w rzędach wielkości iloczynów.

Dla typu Float64, wyniki są znacznie lepsze, ale wciąż niedokładne. Różnice między sumowaniem "w przód"i "w tył"pokazują, że dodawanie zmiennoprzecinkowe nie jest łączne. Prawidłowy wynik jest bardzo bliski zeru. Problem polega na tym, że w sumie występują bardzo duże wartości dodatnie i ujemne, które niemal się znoszą. Tego typu zjawisko często w literaturze nazywane jest katastrofalną anihilacją.

5.4 Wnioski

Kolejność operacji arytmetycznych ma znaczny wpływ na dokładność wyniku. W tym konkretnym przypadku, ze względu na katastrofalną anihilację, żadna z prostych metod sumowania nie daje zadowalającego rezultatu, nawet w podwójnej precyji.

6 Zadanie 6: Numeryczna stabilność wzorów

6.1 Krótki opis problemu

Zadanie polega na porównaniu dwóch matematycznie równoważnych funkcji dla małych wartości argumentu x i ocenie, która z nich jest bardziej wiarygodna w obliczeniach numerycznych.

$$f(x) = \sqrt{x^2 + 1} - 1$$
$$g(x) = \frac{x^2}{\sqrt{x^2 + 1} + 1}$$

6.2 Rozwiązanie

Wzór na f(x) jest podatny na błędy numeryczne dla małych x. W takiej sytuacji $x^2 + 1$ jest liczbą bardzo bliską 1, a $\sqrt{x^2 + 1}$ jest jeszcze bliższe 1. Odejmując od niej 1, dokonujemy odejmowania dwóch bardzo bliskich sobie liczb, co prowadzi utraty precyzji. Wzór na g(x)matematycznie równoważny f(x) nie ma tej wady, ponieważ nie występuje w nim problematyczne odejmowanie.

6.3 Wyniki i interpretacja

Tabela przedstawia wybrane wyniki dla malejących wartości $x = 8^{-i}$.

i	X		f(x)	g(x)		
1	1.25	$\times 10^{-1}$	$7.7822185373186414\times10^{-3}$	$7.7822185373187065\times10^{-3}$		
2	1.5625	$\times 10^{-2}$	$1.2206286282867573\times 10^{-4}$	$1.2206286282875901 \times 10^{-4}$		
3	1.953125	$\times 10^{-3}$	$1.9073468138230965 \times 10^{-6}$	$1.907346813826566 \times 10^{-6}$		
4	2.44140625	$\times 10^{-4}$	$2.9802321943606103\times10^{-8}$	$2.9802321943606116 \times 10^{-8}$		
5	3.0517578125	$\times 10^{-5}$	$4.656612873077393 \times 10^{-10}$	$4.6566128719931904 \times 10^{-10}$		
6	3.814697265625	$\times 10^{-6}$	$7.275957614183426 \times 10^{-12}$	$7.275957614156956 \times 10^{-12}$		
7	4.76837158203125	$\times 10^{-7}$	$1.1368683772161603\times10^{-13}$	$1.1368683772160957 \times 10^{-13}$		
8	5.960464477539063	$\times 10^{-8}$	$1.7763568394002505\times10^{-15}$	$1.7763568394002489 \times 10^{-15}$		
f(x) zaczyna zwracać 0						
9	7.450580596923828	$\times 10^{-9}$	0.0	$2.7755575615628914 \times 10^{-17}$		
10	9.313225746154785	$\times 10^{-10}$	0.0	$4.336808689942018 \times 10^{-19}$		
98	2.010764683385949	$\times 10^{-87}$	0.0	$2.0215873059760975 \times 10^{-174}$		
99	2.513455854232436	$\times 10^{-88}$	0.0	$3.1587301655876523 \times 10^{-176}$		
100	3.141819817790545	$\times 10^{-89}$	0.0	$4.935515883730707 \times 10^{-178}$		

Wyniki pokazują, że wraz ze spadkiem wartości x, funkcja f(x) szybko traci precyzję i od i=9 $(x \approx 7.45 \cdot 10^{-9})$ zwraca 0. W tym samym czasie funkcja g(x) nadal oblicza poprawne, małe, niezerowe wartości.

6.4 Wnioski

Matematycznie równoważne wyrażenia mogą mieć drastycznie różną stabilność numeryczną. Wyniki obliczeń dla funkcji g(x) są wiarygodne, podczas gdy dla f(x) nie. Odejmowanie bliskich sobie liczb w algorytmach może prowadzić do niestabilności numerycznej.

7 Zadanie 7: Różniczkowanie numeryczne

7.1 Krótki opis problemu

Zadanie polega na obliczeniu przybliżonej wartości pochodnej funkcji $f(x) = \sin(x) + \cos(3x)$ w punkcie $x_0 = 1$ przy użyciu wzoru różnicy progresywnej: $f'(x_0) \approx \frac{f(x_0 + h) - f(x_0)}{h}$. Należy zbadać, jak zmienia się błąd przybliżenia w zależności od malejącej wartości kroku $h = 2^{-n}$.

7.2 Rozwiązanie

Wyznaczamy dokładną wartość pochodnej:

$$f'(x_0) = \cos(x) - 3\sin(3x)$$

i porównujemy ją z iteracyjnie wyznaczanym przybliżeniem.

7.3 Wyniki i interpretacja

Prawdziwa wartość pochodnej: $f'(1) \approx 0.11694228168853815$. Tabela przedstawia wyniki dla n od 0 do 54.

\mathbf{n}	1+h	Przyblizenie $f'(x_0)$	Blad bezwzgledny
0	2.0	2.0179892252685967	1.901 046 943 580 058 5
1	1.5	1.8704413979316472	1.753499116243109
2	1.25	1.1077870952342974	$9.908448135457593\times10^{-1}$
3	1.125	$6.232412792975817\times10^{-1}$	$5.062989976090435\times10^{-1}$
4	1.0625	$3.704000662035192\times10^{-1}$	$2.53457784514981 \times 10^{-1}$
5	1.03125	$2.4344307439754687\times10^{-1}$	$1.265007927090087\times10^{-1}$
6	1.015625	$1.8009756330732785\times10^{-1}$	$6.31552816187897\ \times 10^{-2}$
7	1.0078125	$1.484913953710958\times 10^{-1}$	$3.154911368255764\times10^{-2}$
8	1.00390625	$1.327091142805159 \times 10^{-1}$	$1.5766832591977753\times10^{-}$
9	1.001953125	$1.248236929407085 \times 10^{-1}$	$7.881411252170345 \times 10^{-3}$
10	1.0009765625	$1.2088247681106168\times10^{-1}$	$3.9401951225235265\times10^{-}$
11	1.00048828125	$1.1891225046883847\times10^{-1}$	$1.969968780300313\times 10^{-3}$
12	1.000244140625	$1.1792723373901026\times10^{-1}$	$9.849520504721099\times10^{-4}$
13	1.0001220703125	$1.1743474961076572\times10^{-1}$	$4.924679222275685 \times 10^{-4}$
14	1.00006103515625	$1.1718851362093119{ imes}10^{-1}$	$2.462319323930373 \times 10^{-4}$
15	1.000030517578125	$1.1706539714577957{ imes}10^{-1}$	$1.2311545724141837\times10^{-}$
16	1.0000152587890625	$1.1700383928837255\times10^{-1}$	$6.155759983439424 \times 10^{-5}$
17	1.0000076293945312	$1.1697306045971345 \times 10^{-1}$	$3.077877117529937\times 10^{-5}$
18	1.0000038146972656	$1.1695767106721178\times10^{-1}$	$1.5389378673624776\times10^{-}$
19	1.0000019073486328	$1.1694997636368498 \times 10^{-1}$	$7.694675146829866 \times 10^{-6}$
20	1.0000009536743164	$1.1694612901192158{ imes}10^{-1}$	$3.8473233834324105\times10^{-}$
21	1.0000004768371582	$1.169442052487284\times10^{-1}$	$1.9235601902423127{ imes}10^-$
22	1.000000238418579	$1.1694324295967817{ imes}10^{-1}$	$9.612711400208696 \times 10^{-7}$
23	1.0000001192092896	$1.1694276239722967\times10^{-1}$	$4.807086915192826 \times 10^{-7}$
24	1.0000000596046448	$1.1694252118468285\times10^{-1}$	$2.394961446938737\times10^{-7}$
25	1.0000000298023224	$1.16942398250103\ \times 10^{-1}$	$1.1656156484463054\times10^{-}$
26	1.0000000149011612	$1.1694233864545822\times10^{-1}$	$5.6956920069239914\times10^{-}$
27	1.0000000074505806	$1.1694231629371643\times10^{-1}$	$3.460517827846843\times10^{-8}$
28	1.0000000037252903	$1.1694228649139404{\times}10^{-1}$	$4.802855890773117 \times 10^{-9}$
	Błąd zaczyna	a rosnąć z powodu błędów za	okrąglenia
29	1.0000000018626451	$1.1694222688674927{\times}10^{-1}$	$5.480178888461751\times10^{-8}$
30	1.0000000009313226	$1.1694216728210449{\times}10^{-1}$	$1.1440643366000813{ imes}10^-$

n	1+h	Przyblizenie $f'(x_0)$	Blad bezwzgledny
31	1.0000000004656613	$1.1694216728210449\times10^{-1}$	$1.1440643366000813\times10^{-7}$
32	1.0000000002328306	$1.1694192886352539 \times 10^{-1}$	$3.5282501276157063\times10^{-7}$
33	1.0000000001164153	$1.1694145202636719 \times 10^{-1}$	$8.296621709646956 \times 10^{-7}$
34	1.0000000000582077	$1.1694145202636719\times10^{-1}$	$8.296621709646956 \times 10^{-7}$
35	1.0000000000291038	$1.1693954467773438{ imes}10^{-1}$	$2.7370108037771956{\times}10^{-6}$
36	1.000000000014552	1.16943359375 $\times 10^{-1}$	$1.0776864618478044\times10^{-6}$
37	1.000000000007276	$1.169281005859375\times10^{-1}$	$1.4181102600652196\times10^{-5}$
38	1.000000000003638	$1.16943359375 \times 10^{-1}$	$1.0776864618478044\times10^{-6}$
39	1.000000000001819	$1.1688232421875 \times 10^{-1}$	$5.9957469788152196\times10^{-5}$
40	1.0000000000009095	1.168212890625 $\times10^{-1}$	$1.209926260381522\times 10^{-4}$
41	1.0000000000004547	1.16943359375 $\times 10^{-1}$	$1.0776864618478044\times10^{-6}$
42	1.0000000000002274	1.1669921875 $\times10^{-1}$	$2.430629385381522\times 10^{-4}$
43	1.0000000000001137	1.162109375 $\times10^{-1}$	$7.313441885381522\times10^{-4}$
44	1.0000000000000568	1.171875 $\times 10^{-1}$	$2.452183114618478\times10^{-4}$
45	1.0000000000000284	1.1328125 $\times 10^{-1}$	$3.661031688538152\times10^{-3}$
46	1.0000000000000142	1.09375×10^{-1}	$7.567281688538152\times10^{-3}$
47	1.000000000000007	1.09375×10^{-1}	$7.567281688538152\times 10^{-3}$
48	1.0000000000000036	9.375×10^{-2}	$2.3192281688538152{\times}10^{-2}$
49	1.0000000000000018	1.25×10^{-1}	$8.057718311461848 \times 10^{-3}$
50	1.0000000000000009	0.0	$1.1694228168853815\times10^{-1}$
51	1.0000000000000004	0.0	$1.1694228168853815\times10^{-1}$
52	1.0000000000000002	-5.0×10^{-1}	$6.169422816885382 \times 10^{-1}$
53	1.0	0.0	$1.1694228168853815{ imes}10^{-1}$
54	1.0	0.0	$1.1694228168853815\times10^{-1}$

Początkowo błąd maleje wraz ze zmniejszaniem h. Najmniejszy błąd został osiągnięty dla n=28 ($h\approx 3.7\cdot 10^{-9}$). Dalsze zmniejszanie h powoduje wzrost błędu. Gdy h staje się tak małe (n=53), że 1+h jest reprezentowane w maszynie jako 1, licznik staje się zerem, a przybliżenie pochodnej jest błędnie równe 0.

7.4 Wnioski

Wybór kroku h w metodach różnic skończonych jest nietrywialny. Istnieje optymalna wartość h, która minimalizuje błąd przybliżenia. Zarówno zbyt duży, jak i zbyt mały krok prowadzą do niedokładnych wyników.